РЕЗЮМЕ СЕССИИ · ЧИТАТЬ УТРОМ ПЕРВЫМ

slopi-farm — где мы и что дальше

Ночью работал в режиме R&D без платных вызовов. Ферма улучшена и полностью предпроверена; платных денег не потрачено (≈$0.00). Подробности — в `slopi-farm_RnD_2026-10-18_RU.pdf`.

2026-10-18 · 7 коммитов, всё в git

Статус за 30 секунд

- ✅ Ферма адаптирована под OpenRouter, баг пустых ответов (max_tokens) и утечки флагов устранены.
- ✅ ACI-апгрейд: python-recon, промпт под реальные инструменты, точный учёт денег.
- ✅ Новые прототипы **p1–p7** + ручка `--consensus`; инструмент сравнения с графиком.
- ✅ Конвейер доказан end-to-end: **8/8 CORRECT** на чистом бенчмарке (scripted, $0.003, без LLM).
- ⚠️ **Главное:** папка `tasks/` — архив разборов, а не чистые задачи. Прямой платный прогон по ней дал бы недостоверные цифры.
- 🟡 Платных прогонов пока НЕ было (вы просили только R&D). Launcher `START_RUN.command` готов, но см. рекомендацию ниже.

Что запускать (реальный терминал)

Рекомендация: платный прогон делать на ЧИСТОМ бенчмарке — это честное сравнение p1–p7, дёшево (8 задач) и достоверно. Сначала один раз сгенерировать набор (бесплатно):

```
# 0) один раз — ключ и зависимости (если ещё нет)
export OPENROUTER_API_KEY=sk-or-...
cd /Users/karatinos/slopi-popi/farm
python3 -m pip install --user openai httpx pypdf pycryptodome sympy numpy pillow

# 1) чистый бенчмарк готов в репо; при желании перегенерировать:
python3 research/make_clean_bench.py --out research/clean_bench \
    --answer-key data/answer_key_clean.json --selftest

# 2) ПЛАТНЫЙ прогон одного прототипа на чистом бенчмарке (кап $1.5):
source ./env.openrouter.sh
python3 -m farm.cli run --source local --path research/clean_bench \
    --answer-key data/answer_key_clean.json --prototype p1 --limit 1.5 --label real_p1

# 3) сравнить прогоны:
python3 -m farm.compare --glob 'real_p*' --out data/runs/compare_real
```

> Результаты пишутся в `data/runs/outcomes_real_*.json` — я читаю их прямо из общей папки и соберу сравнение. Напишите «готово» после прогона.

Три пути к «настоящему» бенчмарку Кубка

ПУТЬ	ЧТО НУЖНО	ДОСТОВЕРНОСТЬ
A. Чистый бенчмарк (готов)	ничего — запускать p1–p7	высокая (контролируемо), но синтетика
B. Живой CTFd	креды соревнования (были «в другом диалоге»)	высшая — реальные задачи + настоящий скоринг
C. Оригинальные вложения	исходные файлы задач (не разборы)	высокая, если найдёте чистые артефакты

Нужны ваши решения

1. Запускаем платный прогон p1–p7 на чистом бенчмарке (путь A)? Это ~$0.05–0.5 суммарно (8 задач × 7 прототипов, реально дёшево на Flash) — и сразу увидим, какая стратегия лучше.

2. Есть ли у вас креды к живому CTFd Кубка (путь B)? Если да — дайте, и я подключу `CTFdSource` для настоящего замера.

3. Если нужен офлайн-замер именно по задачам Кубка — есть ли где-то ОРИГИНАЛЬНЫЕ вложения (бинарь pwn, pcap форензики, без слайдов-разбора)?

Файлы, которые я оставил

- `research/make_clean_bench.py`, `research/autosolve.py`, `research/clean_bench/`
- `data/answer_key_clean.json`, `data/benchmark_integrity.json`
- `farm/compare.py`, `research/baseline/compare_clean.{png,md}`
- теги git: baseline-prior → refactor-openrouter → bench-ready → integrity-aci → clean-bench → prototypes-p5-p7 → compare-tool

> **Про деньги и изоляцию.** За ночь потрачено ≈$0 (всё на mock/scripted). Песочница на Mac без Docker исполняет код модели без изоляции под вашим пользователем — ок для офлайн-крипто/мисц, не для untrusted-pwn/live-web.