АВТОНОМНАЯ СЕССИЯ R&D · КОНСПЕКТ

slopi-farm — ночной R&D

Разработка и улучшение фермы без платных вызовов: целостность бенчмарка, ACI-апгрейды, чистый бенчмарк + автосолвер, доказательство конвейера, новые стратегии p5–p7, инструмент сравнения. Всё под контролем версий.

2026-10-18, ночь · Claude Opus 4.8 · 7 коммитов поверх baseline

ГЛАВНОЕ
tasks/ = архив разборов
не чистый набор задач → нечестно мерить solve-rate

РЕШЕНИЕ
чистый бенчмарк 8 задач
детерминированный, с референс-солверами

КОНВЕЙЕР
8/8 CORRECT e2e
scripted-провайдер, $0.003, без LLM

СТРАТЕГИИ
p1–p7 + consensus
инструмент сравнения готов

1 · Итог ночи

- **Критическое открытие целостности:** папка `tasks/` — это в основном *разбор* (writeup) материалы (слайды-решения, скрипты-солверы, скриншоты IDA), а не чистые задачи. Прямой прогон по ним дал бы **бессмысленный** solve-rate.
- **Защита:** ферма теперь карантинит файлы-решения (46→далее) и берёт условие только с 1-й страницы PDF, редактируя флаг. 0 утечек флага в условии и в выдаваемых файлах (проверено).
- **Чистый бенчмарк:** сгенерирован набор из 8 самодостаточных офлайн-задач с известными флагами и референс-солверами (selftest ALL PASS) — честная площадка для сравнения прототипов.
- **Автосолвер без LLM** решает 8/8 чистого набора (базовая линия «что берут только инструменты»).
- **Доказан весь конвейер:** scripted-провайдер прогоняет настоящую песочницу и скоринг — 8/8 CORRECT за $0.003. Значит, при платном прогоне «железо» точно отдаёт CORRECT при найденном флаге.
- **ACI-улучшения** поднимают качество любого прототипа на реальном прогоне (python-recon без отсутствующих утилит, промпт под реально доступные инструменты, точная стоимость, ленивые импорты).
- **Новые стратегии p5–p7** + ручка `--consensus` (самосогласованность) + инструмент сравнения с графиком.

2 · Главное открытие — целостность бенчмарка

Автоматический аудит (`data/benchmark_integrity.json`) по 21 задаче:

КЛАСС	ЗАДАЧ	ЗНАЧЕНИЕ
clean-offline	6	есть артефакт, решаемо офлайн (crypto/misc; у ГОСТ на деле нужен оракул)
needs-remote/web	10	нужен живой сервис/веб/бинарь (osint, web, pwn, pentest, часть crypto)
writeup-only	5	чистого артефакта нет — остались только слайды/скриншоты разбора

> **Почему это важно.** PDF в `tasks/` — это «N слайдов в разборе»: на поздних слайдах печатается сам флаг. Многие «данные» — это скриншоты из райтапа (`ida-*.png` , `Pasted image*.png`), а оригинальных бинарей/сервисов нет. Выдать это агенту = отдать ответ. Поэтому честный solve-rate по `tasks/` невозможен; нужен оригинальный набор вложений или живой CTFd (для этого в ферме уже есть `CTFdSource`).

Что сделала ферма для защиты

- условие берётся только с 1-й страницы PDF (титульный слайд) и флаг из него вырезается;
- карантин файлов-решений: по имени (`writeup/solve/solver/unpack/exploit/attack/reference/unseal/gen_cert/разбор` , опечатка `WtiteUP` , каталоги `solver/`) и по полному тексту (все страницы PDF), если там встречается золотой флаг;
- проверено: **0 утечек** флага в условии и во всех выдаваемых файлах.

3 · Улучшения фермы (ACI — ~60–70% ценности по блюпринту)

БЫЛО	СТАЛО	ЗАЧЕМ
recon звал exiftool/binwalk/zbarimg	python-recon (PIL EXIF/GPS, pypdf, tesseract, энтропия, карвинг сигнатур)	этих утилит на Mac НЕТ — агент не тратит шаги/деньги впустую
промпт обещал radare2/gdb/tshark/...	промпт под реально доступные инструменты, python-first	меньше тупиков на платном прогоне
адаптеры тянули httpx всегда	ленивые импорты	офлайн-путь без лишних зависимостей
max_tokens=1024 (пустые ответы)	6144 + контроль reasoning	ранее найденный «пожиратель денег»
оценочная прайс-таблица + undercount	точная стоимость из OpenRouter usage.cost	губернатор точен, потолок жёсткий

4 · Чистый бенчмарк (честная площадка)

`research/make_clean_bench.py` генерирует 8 детерминированных офлайн-задач; у каждой — чистый артефакт, условие без флага, и референс-солвер (selftest ALL PASS):

ЗАДАЧА	ТЕХНИКА	ЗАДАЧА	ТЕХНИКА
crypto/base_chain	b64(hex(flag))	misc/matryoshka	zip→tar.gz→flag
crypto/xor_crib	повторяющийся XOR, криб	misc/morse_wav	Морзе-сигнал
crypto/rsa_toy	близкие простые → Ферма	forensic/png_append	ZIP после IEND (карвинг)
forensic/lsb_stego	LSB в красном канале	reverse/pycheck	инверсия XOR-проверки

Автосолвер без LLM (`research/autosolve.py`) — общая батарея техник (цепочки декодирования, распаковка/карвинг архивов, LSB, Морзе, Ферма-RSA, XOR-криб, инверсия исходника): `8/8` . Это честная нижняя граница «что берут только инструменты, без рассуждения».

5 · Доказательство конвейера (де-риск платного прогона)

> Провайдер `scripted` (`SLOPI_PROVIDER=scripted`) гоняет настоящий ReAct-цикл: list_files → run_python(автосолвер) в реальной песочнице → submit → вердикт. Результат: **8/8 CORRECT** на чистом бенчмарке за **$0.003**, 0 вызовов LLM. Значит весь путь инструменты+песочница+скоринг+леджер работает — при платном прогоне остаётся единственная переменная: рассуждение модели.

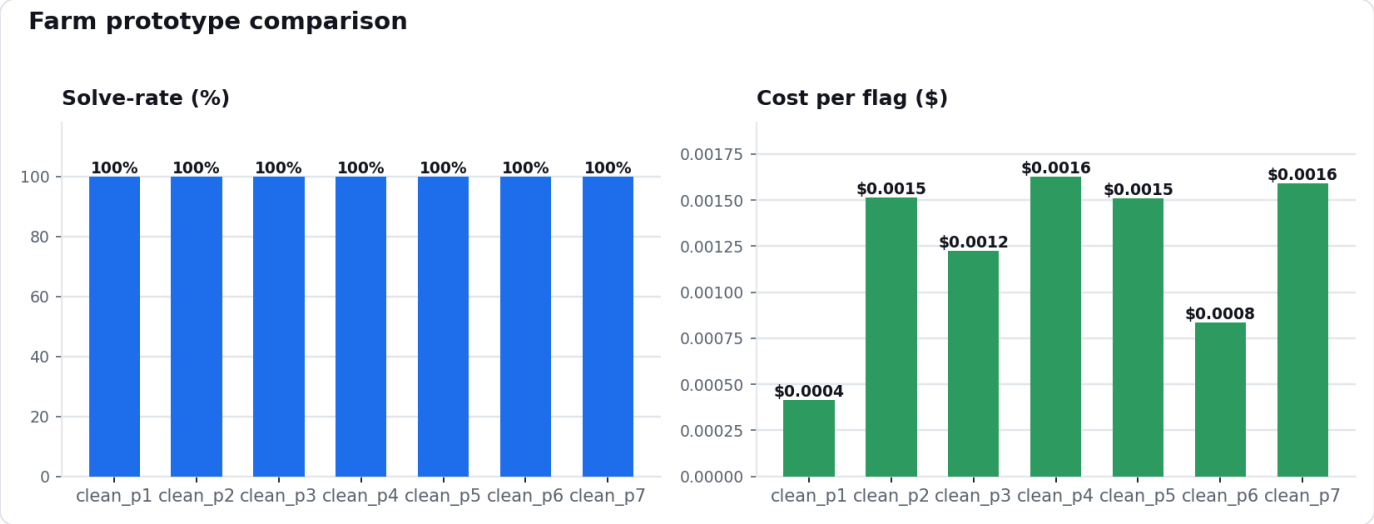
6 · Новые стратегии и прототипы

Все прототипы — конфиги одного движка (честный A/B). Новая ручка `--consensus N` : принять флаг, только если ≥N участников ансамбля независимо его выдали (иначе — не тратить живую отправку на одиночную догадку; при N>1 отключается ранняя отмена, чтобы собрать «голоса»).

P	АНСАМБЛЬ	FLASH→PRO	RECON	ADAPTIVE	CONSENSUS	ТЕЗИС
p1	1	—	—	—	1	базлайн: один агент
p2	4	—	—	—	1	ансамбль + first-to-flag
p3	3	✓	✓	—	1	каскад + recon
p4	4	✓	✓	✓	1	каскад + adaptive
p5	5	—	✓	—	**2**	самосогласованность (точность)
p6	2	✓	✓	✓	1	лёгкий каскад
p7	6	—	—	✓	1	широкий дешёвый охват

7 · Сравнение прототипов (базовая линия на чистом бенчмарке)

Прогон p1–p7 с `scripted`-провайдером (один и тот же «мозг»-автосолвер), поэтому solve-rate одинаков (100%), а вот **стоимость за флаг отличается в 4×** — видно ось «охват↔цена». Различия по solve-rate проявятся только на реальной модели (инструмент сравнения уже готов).



Инструмент: `python -m farm.compare --glob 'clean_p*'` → таблица + график (KPI: solve-rate, spend, cost/flag, median TTF, escalation).

8 · Контроль версий

ТЕГ	ЧТО
baseline-prior	прежний движок
refactor-openrouter	OpenRouter + бенчмарк + прототипы
bench-ready	бриф-PDF в условие + редакция флага
integrity-aci	карантин решений + python-recon + промпт
clean-bench	чистый бенчмарк + автосолвер + scripted
prototypes-p5-p7	consensus + p5/p6/p7
compare-tool	сравнение + базовая линия

9 · Выводы для платного прогона

- **Не тратьте $6 на `tasks/` напрямую** — цифры будут недостоверны (контаминация + нет оригинальных артефактов).
- **Платный прогон лучше всего делать на чистом бенчмарке** — честное, воспроизводимое сравнение p1–p7 по реальному solve-rate/cost-per-flag. Дёшево (8 задач).
- **Для настоящих задач Кубка** нужен либо оригинальный набор вложений/инстансов, либо живой CTFd (адаптер `CTFdSource` в ферме уже есть) — ему нужны креды соревнования.

- Инфраструктура полностью предпроверена на mock/scripted — платные деньги пойдут на измерение, а не на отладку.
