slopi-farm — Прогресс #01

slopi-farm · 2026-09-21 19:39 · Этап 0–1: Control/Data plane, общая память, модельный шлюз

Резюме

Заложен фундамент фермы для решения task-based CTF строго по блюпринту (V2, режим «только API», воркер DeepSeek V4-Flash, эскалация V4-Pro). Реализованы нижние слои: модельный шлюз с учётом стоимости, губернатор бюджета (kill-switch), трейсинг, слой данных (SQLite), общая память роя (blackboard + негативная память + RAG-банк) и конвейер ingest→триаж→верификация. Весь конвейер запускается end-to-end без API-ключа за счёт детерминированного mock-провайдера.

21	20/21	$0.118	mock
задач в корпусе	с эталонным флагом (gold)	модель цены/траектория (док: ~$0.12)	активный провайдер

Что построено (5 слоёв блюпринта)

Слой	Компонент	Модуль	Статус
1 · Control	Конфиг, бюджеты, каскад-политика	farm/config.py	✓
4 · Shared mem	SQLite-хранилище (WAL, DAO)	memory/store.py	✓
4 · Shared mem	Blackboard + негативная память	memory/blackboard.py	✓
4 · Shared mem	Банк решений (RAG, локальные эмбеддинги)	memory/solution_bank.py	✓
Инференс	Модельный шлюз (роутинг Flash/Pro, cost, fallback)	gateway/client.py	✓
Инференс	Провайдеры: DeepSeek + Mock	gateway/providers.py	✓
5 · Observability	Губернатор бюджета + kill-switch	observability/governor.py	✓
5 · Observability	Трейсинг (NDJSON, crash-safe)	observability/tracing.py	✓
Конвейер	Ingest + gold-флаги (карантин)	pipeline/ingest.py	✓
Конвейер	Триаж (категория/сложность/p_solve)	pipeline/triage.py	✓
Конвейер	Верификация + грейдинг + дедуп	pipeline/verify.py	✓

Экономика: модель цены проверена на цифре из документа

Тарифы Flash зашиты из блюпринта: вход miss $0.14/1M, вход cache-hit $0.0028/1M, выход $0.28/1M. Расчёт эталонной траектории (2.5M вход при 80% cache-hit + 0.15M выход) даёт **$0.118** — совпадает с заявленными ~$0.12/траектория. Каждый вызов LLM проходит через шлюз, стоимость каждой траектории учитывается отдельно (основа метрики cost-per-flag).

Корпус задач: ingest и эталонные флаги

25 папок-задач нормализованы в объекты Task. Обнаружено: основные PDF — это разборы/райтапы, часто содержащие сам флаг, а исходные артефакты (pcap/бинарники/живые сервисы) в основном отсутствуют. Поэтому эталонные флаги извлекаются из текстов и **карантинного** зеркала *tasks-with-writeups/* и никогда не показываются агенту. Каждый файл размечен ролью (statement / attachment / spoiler) — для двух режимов оценки (oracle / solve).

Категория	Задач	Комментарий
crypto	3	
forensic	3	
misc	3	
osint	3	
pentest	1	
pwn	2	
reverse	3	
web	3	
ИТОГО	21	20 с gold-флагом, 1 негрейдится (случайный суффикс)

Два режима оценки (честная рамка)

- **oracle** (по умолчанию): агент видит все материалы папки, включая разбор. Измеряет работоспособность всего конвейера + навигацию/извлечение/верификацию + оркестрацию, а также cost-per-flag / time-to-flag.
- **solve** (для реальной модели): разборы/writeup/solver в карантине; агент видит только исходные вводные. Измеряет настоящую решательную способность. Ограничение корпуса: для части задач исходные артефакты отсутствуют, поэтому solve-режим применим не ко всем.

Грабли из блюпринта — как уже закрыты в коде

Антипаттерн (док)	Митигация в ферме
Агент без лимитов → зацикливание	Тройной бюджет (шаги/токены/время) в config.Budgets; stall-детектор
Runaway-затраты	CostGovernor с жёстким kill-switch, подключён к шлюзу
Нет общей памяти	Blackboard + негативная память с 1-го дня
Гомогенный рой из Pro	Каскад Flash→Pro (CascadePolicy, ~15% эскалаций)
Дрожание prefix-кэша	Стабильный префикс; изменяемое (находки) — в конец промпта
Прод без трейсинга	Трейсинг включён с 1-го дня (NDJSON, crash-safe)
Vendor lock-in	Абстракция провайдера в шлюзе (DeepSeek/Mock/др.)
Спойлеры в оценке	Gold-флаги и writeup в карантине, агенту не видны

Дальше

- Ф2: песочница (Docker эфемерная + local fallback), тулкит по категориям, ReAct-агент с тройным бюджетом и детектором застревания.
- Ф1/Ф3: оркестрация (durable-исполнение с чекпойнтами), очередь, knapsack-планировщик, ансамбль с ранней отменой (first-to-flag).
- Прогон корпуса на mock-провайдере → метрики; затем подключение DEEPSEEK_API_KEY и solve-режим.