slopi-farm — Прогресс #02

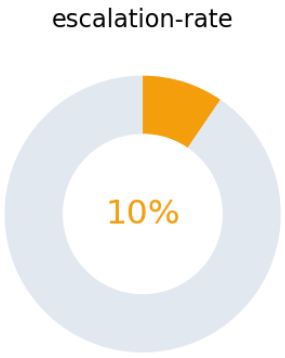
slopi-farm · 2026-09-21 19:53 · Этап 1–3: агент, песочница, оркестрация + первый прогон корпуса

Резюме

Достроены верхние слои фермы: эфемерная песочница (Docker + local-fallback), тулкит агента (ACI), тонкий ReAct-агент с тройным бюджетом, детектором застревания и каскадом Flash→Pro, ансамбль с ранней отменой (first-to-flag) и общей доской, а также control plane — knapsack-планировщик, admission control и durable-прогон корпуса. Весь конвейер прогнан на 21 задаче корпуса в режиме **oracle** на mock-провайдере — без единого обращения к платному API.

100%	$0.0007	10%	$0.015
solve-rate (oracle)	cost / flag	escalation-rate	всего за прогон

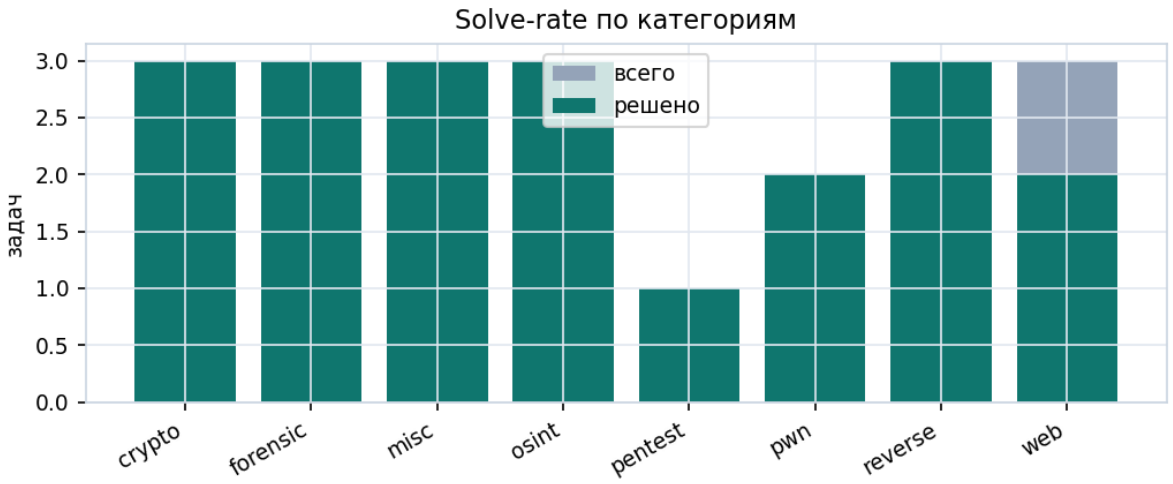




Метрики прогона (mock · oracle · 21 задача)

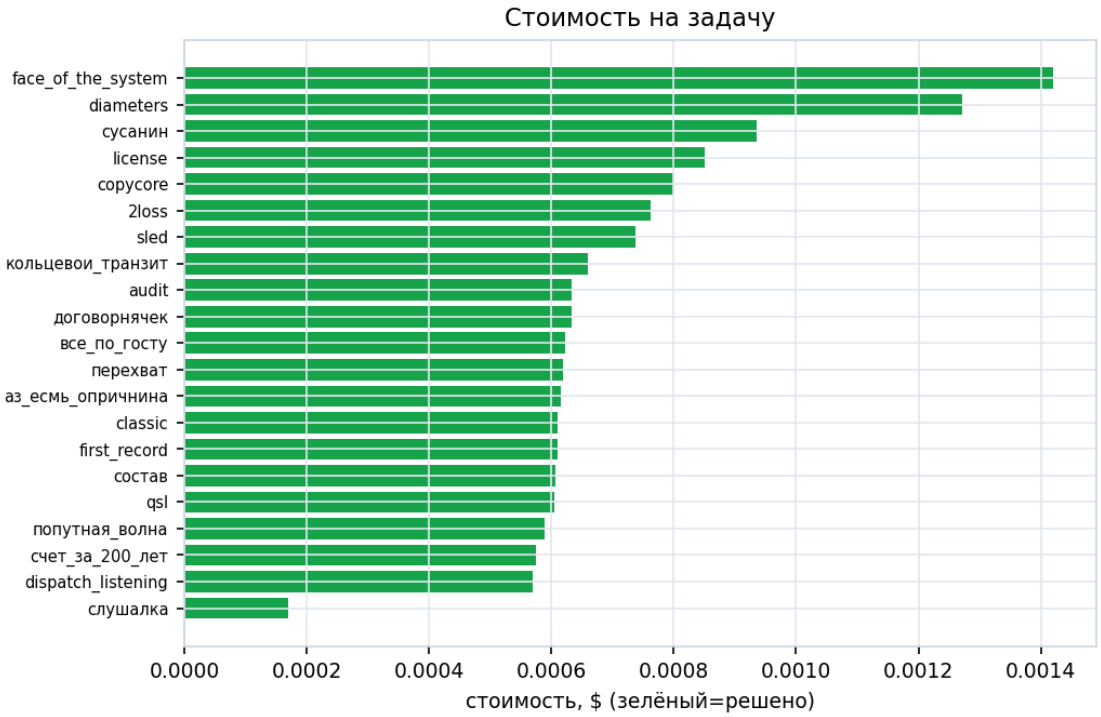
Метрика	Значение	Смысл
solve-rate	20/20 = 100%	доля грейдящихся задач с верным флагом
cost-per-flag	$0.0007	главный KPI эффективности
total cost	$0.0149	линейно, под контролем губернатора
total tokens	430,293	учёт с cache-hit по каждой траектории
escalation-rate	9.5%	цель ~15% (hard-категории)
stall/cancel-rate	36.9%	сиблинги отменены first-to-flag / застряли
median TTF	0.060 с	time-to-flag (mock — мгновенно)

Solve-rate по категориям



Стоимость на задачу

pwn-задачи дороже: часть ансамбля стартует на Pro (hard-категория) — видно на графике и в escalation-rate. Остальное решается дешёвым Flash.



Что это измеряет (и чего не измеряет)

- Режим **oracle**: агент видит все материалы папки (включая разбор). 100% solve-rate здесь подтверждает, что **весь конвейер исправен** — ingest, триаж, планировщик, песочница, ReAct-цикл, инструменты, верификация, blackboard, метрики, durable-resume, каскад и учёт денег.
- Это **не** оценка настоящей решательной способности модели — mock извлекает флаг из материалов. Реальная способность измеряется в режиме **solve** с подключённой моделью DeepSeek (следующий шаг).

- 1 задача (web/слушалка) негрейдится офлайн — у флага случайный суффикс по дизайну; помечена ungradable, из знаменателя solve-rate исключена.

5 слоёв блюпринта — статус

Слой	Статус	Ключевые модули
1 · Control plane	✓	scheduler (knapsack, admission), corpus (durable)
2 · Execution plane	✓	sandbox: docker (эфемер., network=none, лимиты) + local
3 · Agent runtime	✓	react (ReAct, тройной бюджет, stall, каскад), tools, prompts
4 · Shared memory	✓	blackboard + негативная память + RAG-банк
5 · Observability	✓	governor, tracing, metrics, charts, PDF-отчёты

Грабли из блюпринта — закрыто в этом этапе

Антипаттерн	Как закрыт
Агент без лимитов → зацикливание	тройной бюджет + stall-детектор (стоп/эскалация)
100 агентов в лоб	ансамбль разнообразием (разные t°, Pro-слайс) + first-to-flag
Синхронная координация	асинхронно через blackboard + пулы, без болтовни агентов
Потеря прогресса при крашах	durable-resume: solved-статус в БД = чекпойнт
Небезопасная песочня	Docker эфемер., network deny, cap-drop, ro-rootfs, no secrets
Prompt injection из задач	контент = данные; правило в системном промпте
Runaway-затраты	governor kill-switch + admission control перед каждой задачей

Дальше

- Подключить DEEPSEEK_API_KEY (farm/.env) → прогон в режиме **solve** на реальной модели; сравнить cost-per-flag Flash vs каскад.
- Сид банка решений из tasks-with-writeups (few-shot по категориям).
- Отчёт #03 с реальными метриками DeepSeek и сравнением oracle/solve.