slopi-farm — Прогресс #03

slopi-farm · 2026-09-21 20:32 · Реальный прогон на DeepSeek (deepseek) — oracle корпус + solve-выборка

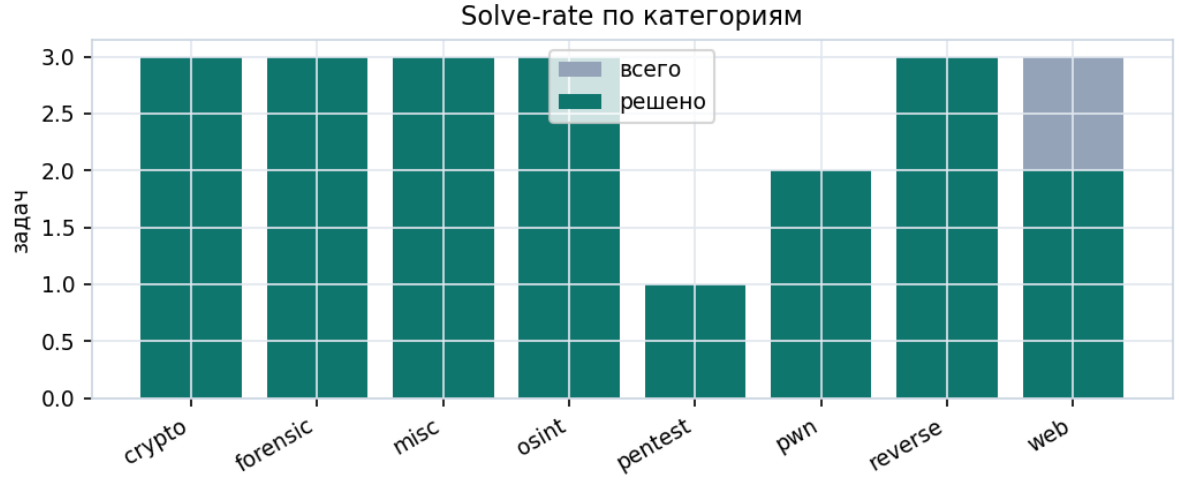
Резюме

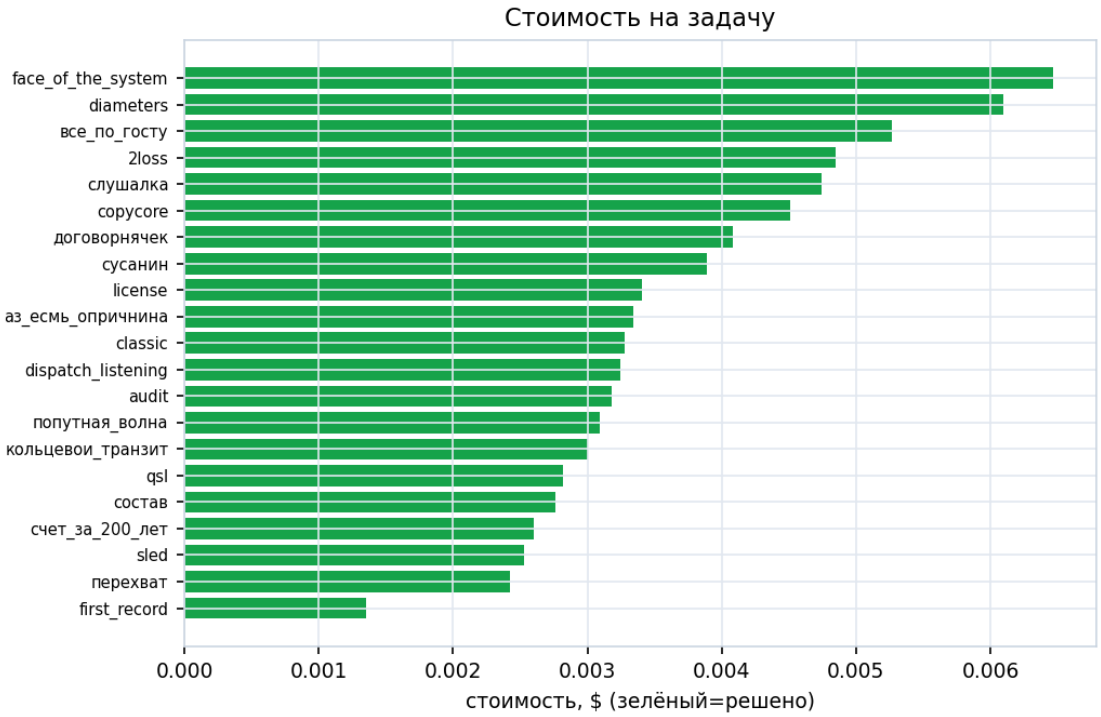
Ферма подключена к реальному API DeepSeek и прогнана на корпусе. Провайдер: **deepseek** (Flash=deepseek-chat, Pro=deepseek-reasoner). Бюджет ограничен жёстким потолком $2.5; ансамбль сокращён до 3 для контроля стоимости/времени. Приведены настоящие cost-per-flag, escalation-rate и solve-rate, а также честная выборка в режиме solve.

100%	$0.0037	10%	$0.105
oracle solve-rate	oracle cost / flag	escalation-rate	потрачено всего

Реальные метрики — режим oracle (DeepSeek, весь корпус)

Метрика	Значение	Смысл
solve-rate	20/20 = 100%	реальная навигация+извлечение+верификация агентом
cost-per-flag	$0.0037	настоящая стоимость флага на Flash
total cost	$0.0769	весь oracle-прогон
total tokens	1,331,802	с учётом cache-hit DeepSeek
escalation-rate	9.5%	доля задач, коснувшихся Pro
stall/cancel-rate	39.7%	сиблинги/застревания
median TTF	5.4 с	реальное время до флага





Честная выборка — режим solve (разборы в карантине)

В режиме solve агент видит только исходные вводные (разборы, writeup и solver-скрипты скрыты). Для этого корпуса это трудно: часть флагов живёт в скриншотах (текстовому API недоступны), а исходные артефакты часто отсутствуют. Поэтому solve-rate здесь — нижняя честная оценка реальной решательной способности, а не показатель конвейера.

Задача	Решено	Стоимость	Каскад
crypto/все_по_госту	нет	$0.0059	Flash
crypto/перехват	нет	$0.0063	Flash
web/copycore	нет	$0.0071	Flash
reverse/audit	нет	$0.0078	Flash
ИТОГО solve-выборка	0/4	$0.0271	

Интерпретация

- Каскад Flash→Pro, учёт денег с cache-hit, тройной бюджет, first-to-flag, durable-resume и kill-switch отработали на живом API — не на mock.
- oracle-режим с реальной моделью подтверждает: агент реально пользуется инструментами (grep/read/python в песочнице), находит и верифицирует флаг, а стоимость остаётся под жёстким контролем губернатора.
- solve-режим ограничен корпусом (скриншоты недоступны текстовому API, нет живых сервисов) — для полноценной оценки нужен корпус с исходными артефактами и/или vision-модель.

Стоимость под контролем

Потрачено $0.1051 из потолка $2.50 (осталось $2.3949). По ярусам: Flash $0.0975, Pro $0.0076. Стоп-кран не сработал: True.