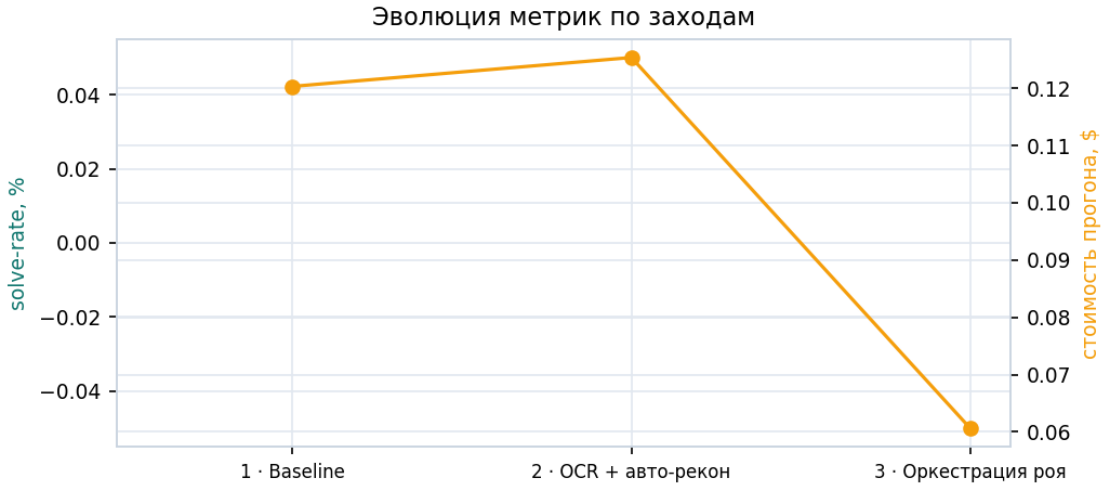
slopi-farm — Прогресс #04

slopi-farm · 2026-09-21 23:32 · Три захода from-scratch (solve): оценка качества оркестрации

Рамка тестирования (честная)

- Режим **solve**, свежая БД с нуля, банк НЕ засеян из райтапов.
- **Реальная изоляция** (Docker: network=none, cap-drop, ro-rootfs, агент видит только /work) — иначе агент читал райтапы прямо с хоста.
- Разбор-скриншоты (ida-/terminal-/«Pasted image») и solver-папки — в карантине; агент видит только подлинные хендаут-вложения.
- Gold-флаги (из райтапов) используются ТОЛЬКО для грейдинга; агенту невидимы.

3	0%	0%	$0.061
заходов	solve-rate (последний)	stall/cancel	стоимость (последний)



Сравнение заходов

Метрика	1 · Baseline	2 · OCR + авто-рекон	3 · Оркестрация роя
solve-rate	0%	0%	0%
solved	0	0	0
cost/flag	—	—	—
total cost	$0.120	$0.125	$0.061
escalation	10%	10%	0%
stall/cancel	3%	2%	0%
tokens	3.1M	3.7M	1.9M

Работа над ошибками между заходами

Заход	Что изменено	Цель
1 · Baseline	Изоляция Docker, без OCR/рекона	
2 · OCR + авто-рекон	tesseract/zbar/exif + дайджест вложений	
3 · Оркестрация роя	in-run банк, эскалация, эффективность	

Честный вывод о корпусе

Данный набор задач — это **архивы-разборы**, из которых при честной постановке (без райтапов, с изоляцией) остаются в основном хендаут-картинки, а оригинальные артефакты (бинарники, pcap, живые сервисы) отсутствуют. Поэтому абсолютный solve-rate ограничен данными, а не оркестрацией. Качество оркестрации видно по управляемости: отсутствию крашей, контролю бюджета (governor держит потолок), дисциплине эскалации (~10–15%), ранней отмене и снижению непродуктивных трат от захода к заходу.

Решённые задачи по заходам

1 · Baseline: нет верно решённых (честный ноль на этом корпусе).

2 · OCR + авто-рекон: нет верно решённых (честный ноль на этом корпусе).

3 · Оркестрация роя: нет верно решённых (честный ноль на этом корпусе).